

Directives & Cahier des Charges du Mini-Projet

Cours de Data Mining (Fouille de Données)

Année Académique : 2026/2027

Toutes les nouvelles mises à jour seront disponibles ici

EN BREF — RÈGLES ET MODALITÉS DU PROJET

- **Taille des Équipes** : De 3 étudiants minimum to 6 étudiants maximum par groupe.
- **Taille du Jeu de Données** : Minimum 10 000 enregistrements valides avant tout prétraitement ($\geq 10\,000$ lignes brutes) et au moins 10 attributs. (Le jeu nettoyé peut contenir $< 10\,000$ lignes).
- **Domaine applicatif** : Libre choix (Santé, Finance, E-commerce, Vision, NLP, Énergie, etc.).
- **Parcours Technique** : Classification Supervisée OU Clustering Non Supervisé (ou Hybride). Modèles du cours obligatoires, extension autorisée à d'autres algorithmes ML classiques. **Deep Learning et LLM strictement interdits comme modèles ML.**
- **Usage des LLM** : Autorisé uniquement comme **outil applicatif d'assistance** (explicabilité, synthèses), PAS comme modèle prédictif principal.
- **Optimisation** : **Au moins une méthode systématique (GridSearchCV ou RandomizedSearchCV)** obligatoire pour les modèles réglables (Zero-R exempté).
- **Tests Statistiques** : **Au moins 2 tests/analyses statistiques** scientifiquement appropriés et explicitement justifiés.
- **Livrable Applicatif & Déploiement** : Application fonctionnelle (Streamlit/Gradio/Flask/Desktop). **Déploiement en ligne optionnel**, exécution locale fonctionnelle obligatoire. Stockage externe adapté pour les données volumineuses (> 100 Mo).
- **Modalités de Rendu** : **Pas de soutenance orale.** Évaluation uniquement sur le **Rapport PDF** (docs/Rapport_MiniProject.pdf) et le **Dépôt GitHub complet.**
- **Hébergement Git & Traçabilité** : Dépôt GitHub public obligatoire. **Historique des commits analysé individuellement.**

1. Objectifs et Philosophie du Mini-Projet

Le mini-projet constitue le pilier pratique du cours de **Data Mining**. Son objectif est de placer les étudiants dans la posture d'ingénieurs et de Data Scientists confrontés à un problème du monde réel.

Chaque équipe devra réaliser l'intégralité de la chaîne de traitement de données (*End-to-End Data Pipeline*), depuis la collecte et le prétraitement des données brutes jusqu'au déploiement d'une

application décisionnelle interactive intégrant les algorithmes découverts en cours.

2. Organisation des Équipes et Suivi Git Strict

2.1. Composition des Groupes & Affectation Obligatoire

- **Liberté de Constitution** : Les étudiants sont totalement libres de constituer leur propre groupe (de **3 étudiants minimum** à **6 étudiants maximum**).
- **Affectation Obligatoire** : Les étudiants n'ayant pas rejoint d'équipe à la date limite d'inscription seront regroupés d'office par l'enseignant au sein de groupes imposés pour réaliser un projet obligatoire.

2.2. Gestion de Version et Engagement Git

RECOMMANDATION & ENGAGEMENT GIT (TRAÇABILITÉ INDIVIDUELLE)

1. Le projet doit être intégralement hébergé sur un dépôt **GitHub public**.
2. **Chaque membre du groupe doit posséder son propre compte GitHub** et contribuer activement par des commits réguliers, des branches explicites et des Pull Requests.
3. L'évaluation de l'implication individuelle sera effectuée via l'analyse des statistiques Git (*Git Commit History, Lines added/deleted, Pull Requests merged*).
4. **Engagement Git** : Pour garantir une évaluation équitable du travail d'équipe et valoriser l'implication de chacun, le suivi des contributions individuelles s'effectue via l'historique des commits Git. Chaque membre est vivement encouragé à commiter régulièrement ses propres travaux. Une contribution très faible, tardive ou symbolique (ex: un unique commit la veille du rendu) entraînera une réévaluation individuelle pouvant impacter la note attribuée.

2.3. Règle d'Anonymisation sur les Supports Publics

CONFIDENTIALITÉ ET ANONYMAT SUR LES SUPPORTS PUBLIC

Dans l'ensemble des données et documents publics (**Dépôt GitHub**, README.md, Notebooks, Code source et **Rapport PDF**), **il est strictement interdit de mentionner les noms et prénoms réels des étudiants**.

- Seul le **code de l'étudiant** doit être utilisé.
- **Format du Code Étudiant** : Spécialité + Numéro d'ordre dans la liste du groupe (exemple : IASD01, IASD02, IASD03 pour le 3ème membre du groupe de la spécialité IASD).

2.4. Politique d'Utilisation des Outils d'IA et Encadrement Scientifique

POLITIQUE D'USAGE DES OUTILS D'IA ET DISTINCTION ML VS IA APPLICATIVE

1. **Usage Autorisé pour la Rédaction & Débogage** : L'utilisation des assistants d'IA (ChatGPT, Claude, Gemini, Copilot) est **autorisée** pour la rédaction, la recherche documentaire et le débogage.
2. **Interdiction des LLM et Deep Learning comme Modèles ML** : Les modèles de Deep Learning (PyTorch, TensorFlow, CNN, RNN, Transformers) et les LLM sont **strictement interdits en tant que modèles de classification ou de clustering principaux**.
3. **LLM Autorisés uniquement comme Outils Applicatifs** : Les LLM peuvent en revanche être intégrés au niveau de l'interface applicative comme **outil d'assistance ergonomique** (ex: générer des explications textuelles des prédictions, des synthèses ou des conseils métiers), sous réserve que le moteur de prédiction repose sur un modèle ML classique.
4. **Responsabilité Pédagogique Totale** : Les étudiants demeurent **100% responsables** de l'exactitude scientifique, mathématique et du code.
5. **Convocation à une Audition Orale** : En cas de suspicion d'utilisation d'IA non maîtrisée (hallucinations, concepts incohérents), **les étudiants concernés seront convoqués individuellement à une audition orale d'évaluation**.

3. Exigences sur le Jeu de Données et le Domaine Applicatif

3.1. Choix du Domaine Applicatif

Le choix du domaine métier est totalement libre afin de permettre à chaque groupe de travailler sur une thématique passionnante (Finance, Santé, E-commerce, Transport, Vision, NLP, etc.).

3.2. Volumétrie et Caractéristiques des Données

- **Volume Minimal Initial** : Le dataset choisi doit comporter au **strict minimum 10 000 observations valides avant tout prétraitement** ($\geq 10\,000$ enregistrements bruts).
- **Volume Après Nettoyage** : Après l'étape de nettoyage et de filtrage (ex: suppression des valeurs manquantes ou des outliers), le dataset nettoyé résultant peut valablement comporter moins de 10 000 observations.
- **Nombre d'Attributs** : Le dataset doit contenir au **minimum 10 attributs** (variables numériques, catégoriques ou textuelles).
- **Stockage des Données Volumineuses (> 100 Mo)** : Si le jeu de données est volumineux ou dépasse les limites conseillées de GitHub, l'équipe doit utiliser une plateforme de stockage externe appropriée (ex: Kaggle, Google Drive, Zenodo, OSF, Hugging Face Datasets) et fournir un script de téléchargement automatique ou une procédure explicite dans le **README.md** pour le fonctionnement local.
- **Sources recommandées** : Kaggle, UCI Machine Learning Repository, Google Dataset Search, data.gov, OpenData.

4. Parcours Techniques et Algorithmes du Cours

Chaque groupe doit choisir l'un des deux parcours principaux (ou proposer une approche hybride combinant les deux). Les algorithmes vus en cours constituent le socle obligatoire, mais les équipes sont **libres d'étendre leur benchmark à d'autres algorithmes ML classiques** (ex: XGBoost, LightGBM, CatBoost, Extra Trees, DBSCAN, GMM). **Rappel** : Les modèles Deep Learning et LLM sont strictement interdits comme modèles de Machine Learning.

PARCOURS A : CLASSIFICATION SUPERVISÉE

Si vous choisissez la classification supervisée, vous devez obligatoirement implémenter et comparer les algorithmes suivants (sans s'y limiter) :

1. **Classifieur de Référence (Baseline)** : Classifieur Naïf / Zero-R (Exempté d'optimisation d'hyperparamètres).
2. **K-Nearest Neighbors (K-NN)** : Étude du paramètre K , métriques de distance et standardisation.
3. **Arbres de Décision & Random Forest** : Gain d'information, Indice de Gini, élagage et importance des variables.
4. **Classifieur Naïve Bayes** : GaussianNB, MultinomialNB ou BernoulliNB avec lissage de Laplace.
5. **Support Vector Machines (SVM)** : Noyaux (Linéaire, RBF, Poly) et tuning (C, γ).

Optimisation Obligatoire : Au moins une méthode d'optimisation systématique des hyperparamètres (GridSearchCV ou RandomizedSearchCV avec validation croisée K -Fold, $K \geq 5$) est **obligatoire pour tous les modèles possédant des hyperparamètres réglables**.

PARCOURS B : CLUSTERING NON SUPERVISÉ

Si vous choisissez le clustering non supervisé, vous devez obligatoirement implémenter et comparer les familles suivantes (sans s'y limiter) :

1. **Méthodes de Partitionnement** :
 - **K-Means** : Méthode du coude (*Elbow Method*) et initialisation K -Means++.
 - **K-Medoids (PAM)** : Comparaison de la robustesse aux valeurs aberrantes.
2. **Méthodes Hiérarchiques** :
 - **AGNES (Agglomératif)** : Dendrogrammes avec liaisons (Ward, Complete, Single, Average).
 - **DIANA (Divisif)** : Analyse top-down de la séparation des clusters.

Optimisation Obligatoire : Balayage méthodique des hyperparamètres clés (ex: nombre de clusters K , métriques de liaison) via GridSearchCV ou recherche systématique évaluée sur les métriques de validation.

5. Développement de l'Application Interactive

Chaque groupe doit développer une **application utilisateur fonctionnelle** (Streamlit, Gradio, Dash, Flask ou Desktop).

Directives relatives au Déploiement et à l'Accès aux Données :

- **Déploiement en Ligne Optionnel :** Le déploiement en ligne (Cloud) est **optionnel**. L'application doit néanmoins s'exécuter sans erreur en local en suivant la procédure documentée dans le `README.md`.
- **Gestion des Données :** Toutes les données nécessaires à l'exécution doivent être présentes ou téléchargeables automatiquement depuis un stockage externe adapté si le volume est important.

Exigences Minimales Obligatoires pour le Dashboard EDA : Le dashboard d'exploration (EDA) au sein de l'application doit proposer au **strict minimum les 6 éléments suivants** :

1. **Statistiques Descriptives Synthétiques :** Tableau complet des métriques de tendance centrale et de dispersion.
2. **Informations sur les Valeurs Manquantes :** Visualisations et taux de présence des données manquantes par attribut.
3. **Distributions des Variables Numériques :** Histogrammes et courbes de densité KDE des variables quantitatives.
4. **Visualisation des Fréquences Catégorielles :** Graphiques en barres de la répartition des attributs qualitatifs.
5. **Analyse de Corrélation Numérique :** Matrice / Heatmap de corrélation pour les attributs numériques.
6. **Au moins un Mécanisme de Filtrage Interactif :** Filtres dynamiques (curseurs, menus déroulants, sélecteurs) permettant de filtrer les données en temps réel.

6. Structure Obligatoire du Dépôt GitHub & Contenu du README.md

6.1. Arborescence Standardisée du Projet

Chaque équipe doit respecter la structure de projet standardisée suivante dans son dépôt GitHub :

```
nom-du-projet-datamining/
|-- README.md           # Documentation principale (Instructions, Rôles, Objectifs, Rés
|-- data/
|   |-- raw/            # Données brutes (ou script/liens de téléchargement si > 100 Mo)
|   '-- processed/      # Données nettoyées et transformées
|-- notebooks/          # Notebooks Jupyter structurés étape par étape
|   |-- 01_eda_and_cleaning.ipynb
|   |-- 02_preprocessing_encoding.ipynb
|   '-- 03_model_training_evaluation.ipynb
|-- src/                # Code source Python complet de l'application
|   |-- app.py           # Point d'entrée principal de l'application (ex: Streamlit)
|   |-- preprocessing.py # Fonctions de nettoyage et préparation
|   '-- models.py        # Chargement des modèles et fonctions de prédiction
|-- docs/               # Rapport scientifique complet au format PDF
|   '-- Rapport_MiniProject.pdf
'-- requirements.txt     # Liste exacte des dépendances Python (pandas, scikit-learn, et
```

6.2. Contenu Exigé du Fichier README.md sur GitHub

Le fichier README.md constitue le **rapport GitHub principal** de votre projet. Il doit obligatoirement inclure les 4 sections suivantes :

SECTION 1 : Présentation, Objectifs et Description du Projet

- Titre clair du projet et contexte métier.
- Description détaillée des objectifs scientifiques et applicatifs.
- Présentation du dataset (source, $\geq 10\,000$ enregistrements bruts initiaux, au moins 10 attributs).

SECTION 2 : Guide d'Installation, Exécution Locale et Accès aux Données

- Instructions étape par étape pour cloner le dépôt, installer les dépendances et exécuter l'application localement.
- Procédure d'accès / téléchargement des données si stockage externe utilisé (> 100 Mo).
- URL de déploiement en ligne si disponible (optionnel).

SECTION 3 : Rôles des Membres et Matrice des Contributions

Tableau explicite détaillant les responsabilités exactes de chaque étudiant (**Règle d'anonymat** : utiliser uniquement le Code Étudiant, aucun Nom/Prénom réel).

SECTION 4 : Résultats Clés et Synthèse des Découvertes

- Tableau synthétique comparant les performances de tous les modèles testés.
- Justification des choix d'optimisation d'hyperparamètres et des tests statistiques réalisés.

7. Grille d'Évaluation Hyper-Détaillée (Barème sur 20 Points)

L'évaluation repose sur un barème analytique sous-fractionné sur **20.0 Points**, évaluant chaque sous-élément technique du projet :

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
PARTIE 1 : RIGUEUR TECHNIQUE & DATA MINING (TOTAL : 10.0 POINTS)		
1.1 Prétraitement des Données	Nettoyage des valeurs manquantes/aberrantes, encodage des variables (One-Hot/Label/Binary), normalisation/standardisation (Z-score/Min-Max). Dataset initial $\geq 10\,000$ lignes brutes et ≥ 10 attributs.	2.0 pts
1.2 EDA & Tests Statistiques	Visualisations des distributions, corrélation, et réalisation obligatoire d'au moins 2 tests/analyses statistiques appropriés (χ^2 , test t / Mann-Whitney U , ANOVA, Shapiro-Wilk, Pearson/Spearman). Justification explicite exigée du choix de chaque test.	3.0 pts

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
1.3 Implémentation des Modèles ML	Implémentation et comparaison des algorithmes du cours pour le parcours choisi. Extension possible à d'autres algorithmes ML classiques. Deep Learning et LLM strictement interdits comme modèles ML.	1.0 pt
1.4 Optimization & Cross-Validation	Application obligatoire d'au moins une méthode d'optimisation systématique (GridSearchCV ou RandomizedSearchCV avec K -Fold $K \geq 5$) pour tous les modèles réglables (Zero-R exempté).	2.0 pts
1.5 Analyse des Métriques Comparatives	Tableau comparatif multicritère complet, matrices de confusion, courbes ROC-AUC, Precision/Recall/F1-Score (ou Silhouette $s(i)$, Davies-Bouldin DBI , Rand Index RI).	2.0 pts
PARTIE 2 : APPLICATION INTERACTIVE & ERGONOMIE (TOTAL : 4.0 POINTS)		
2.1 Architecture & Stabilité UI	Application fonctionnelle exécutable localement (déploiement cloud optionnel), absence de bugs, code propre dans <code>src/app.py</code> . Gestion appropriée des jeux de données volumineux sur stockage externe.	1.5 pts
2.2 Dashboard EDA Interactif	Dashboard comprenant au minimum les 6 éléments exigés : stats descriptives, données manquantes, distributions numériques, fréquences catégorielles, corrélation et au moins 1 filtre interactif.	1.0 pt
2.3 Prédiction / Clustering Temps Réel	Formulaire interactif de saisie dynamique générant des prédictions/clustering instantanés avec probabilité/confiance. (Intégration d'un LLM autorisée uniquement comme outil applicatif d'explicabilité/conseil).	1.5 pts
PARTIE 3 : TRAÇABILITÉ GIT & COMMITS INDIVIDUELS (TOTAL : 3.0 POINTS)		
3.1 Discipline & Structure du Dépôt	Respect strict de l'arborescence recommandée (<code>data/</code> , <code>notebooks/</code> , <code>src/</code> , <code>docs/</code>), présence du fichier <code>requirements.txt</code> et clarté des messages de commit.	1.0 pt
3.2 Commits & Contributions Individuelles	Régularité des commits personnels par étudiant sur GitHub. Note : Pénalité de 0/20 attribuée individuellement si l'historique d'un membre est vierge.	2.0 pts
PARTIE 4 : RAPPORT PDF & DOCUMENTATION GITHUB (TOTAL : 3.0 POINTS)		
4.1 Rapport Scientifique PDF	Rapport académique rédigé dans <code>docs/Rapport_MiniProject.pdf</code> (Problématique, méthodologie, justifications théoriques des algorithmes et des tests statistiques, interprétation des résultats).	1.5 pts
4.2 Documentation README.md GitHub	Fichier <code>README.md</code> exemplaire avec guide d'installation local pas-à-pas, accès aux données, matrice des rôles/contributions nominative et synthèse des résultats.	1.5 pts
TOTAL GÉNÉRAL	Évaluation Finale du Mini-Projet (Sans Soutenance Orale)	20.0 pts

INTÉGRATION DANS LA NOTE FINALE DE TP & EXAMENS

- **Calcul de la Note Finale de TP (sur 20 Points) :** La note du mini-projet est sur 18 points. La note globale des 6 épreuves TP est sur 18 points. La moyenne des deux parties est additionnée aux 2 points de la Note de l'Enseignant :

$$NoteFinaleTP = \frac{Projet_{/18} + TestsTP_{/18}}{2} + NoteEnseignant_{/2}$$

- **Exercices Vrai / Faux du TP dans les Examens et Devoirs :** Les questions "Vrai / Faux" faites en TP sont intégrées sous forme d'une section notée sur **5 points** dans chaque examen final et devoir à la maison.
- **Tentatives Illimitées en TP :** Nombre illimité de tentatives en séance TP. La note retenue pour chaque TP est la moyenne arithmétique de toutes vos tentatives valides.

8. Exemple d'Application Référence & Ressources d'Illustration

Pour illustrer concrètement l'ensemble des exigences du cahier des charges, un **projet modèle de référence complet** a été développé et rendu public. Ce projet démontre la qualité attendue sur la chaîne Data Mining, l'application web et la documentation.

PROJET MODÈLE : PRÉDICTION DU RISQUE CARDIAQUE PAR DATA MINING

- **Thématique Métier :** Santé & Cardiologie Prédictive (Diagnostic assisté non invasif).
- **Jeu de Données :** Kaggle [uditjain13/heart-disease-risk-2026](#) ($N = 9\,000$ enregistrements, 25 attributs).
- **Traitements :** Encodage et standardisation sans fuite de données (`ColumnTransformer`), 6 tests statistiques (χ^2 , Mann-Whitney U , Spearman) avec corrections Benjamini-Hochberg FDR.
- **Modélisation :** Benchmark de 6 classifieurs (Zero-R, K-NN, Arbre, Random Forest, Naïve Bayes, SVM). Le SVM (RBF) obtient une Accuracy de **89,17%** et un ROC-AUC de **0.9422**.
- **Application Déployée :** Dashboard Streamlit 9 pages avec une échelle de stratification clinique à 7 niveaux (0% à 100%) et des curseurs interactifs.

ATTENTION — TRAVAIL MINIMUM ATTENDU

Remarque Importante : Ce projet modèle de référence (*Prédiction du Risque Cardiaque par Machine Learning & Web App*, Jeu de données Kaggle [uditjain13/heart-disease-risk-2026](#), $N = 9\,000$ enregistrements, 25 attributs, benchmark de 6 classifieurs avec SVM RBF atteignant 89.17% d'Accuracy et 0.9422 de ROC-AUC) constitue le **niveau de réalisation MINIMUM attendu** de la part de chaque équipe d'étudiants.

8.1. Liens Directs vers les Ressources en Ligne

- **Dépôt GitHub Public :** [Consulter le Dépôt GitHub Exemple](#)
- **Application Web Déployée (Live Streamlit Cloud) :** [Tester l'Application Live dmproject2.streamlit.app](#)

- Exemple de Rapport Scientifique PDF (40 pages) : [Consulter le Rapport PDF Exemple \(40 pages\)](#)

8.2. Captures d'Écran et Visualisations de Performance Référence




Figure 1: Comparaison des Courbes ROC (Discrimination maximale SVM AUC = 0.9422).




Figure 2: Grille des Matrices de Confusion des 6 Algorithmes Benchmarqués.




Figure 3: Analyse Multi-Perspective des Variables Clés (Fréquence Cardiaque Max, Dépression ST, Âge, LDL).

9. Modalités de Communication, Suivi et Directives Obligatoires par Email

DIRECTIVES OFFICIELLES DE COMMUNICATION, DE SUIVI ET DE RENDU

Principe général.

Afin de garantir une communication centralisée, une traçabilité complète des échanges et un suivi équitable de l'avancement des différents groupes, l'ensemble des communications officielles relatives au projet de Data Mining doit obligatoirement être effectué par l'intermédiaire de l'adresse email officielle du projet :

`datamining.project.student@gmail.com`

Important : les communications officielles doivent être envoyées **exclusivement par le chef de groupe (*Team Leader*)**. Les membres d'un groupe peuvent participer à la préparation du contenu du message, mais le *Team Leader* demeure le responsable de l'envoi et du suivi des échanges avec l'équipe pédagogique.

Pour faciliter l'identification automatique des messages et assurer leur classement, chaque email doit respecter strictement le format d'objet correspondant à sa nature. Tout email ne respectant pas les conventions définies ci-dessous pourra être retardé dans son traitement ou nécessiter une nouvelle soumission correctement formatée.

1. Cycle officiel de communication

Les échanges relatifs au projet sont organisés autour de trois étapes principales :

1. Étape 1 – Déclaration obligatoire de l'équipe et du sujet

Date limite : 15 septembre 2026

Avant le **15 septembre 2026**, chaque *Team Leader* doit envoyer un email officiel permettant d'enregistrer définitivement son groupe et son sujet de projet.

Destinataire obligatoire :

`datamining.project.student@gmail.com`

Format obligatoire de l'objet :

`[DM-2026] [INSCRIPTION] Groupe <Code_Leader> - <Nom_du_Projet>`

Exemple :

`[DM-2026] [INSCRIPTION] Groupe IASD01 - Prédiction Risque Cardiaque`

Le corps de l'email doit obligatoirement contenir :

- le code étudiant du *Team Leader* ;
- les codes étudiants de tous les membres du groupe ;
- le nom ou titre provisoire du projet ;
- le domaine métier ou domaine d'application ;
- une description claire du problème à résoudre ;
- une description du ou des datasets envisagés ;
- la source du dataset et, lorsque cela est possible, son URL ;
- le nombre approximatif d'observations et de variables ;
- la variable cible (*target*) envisagée, lorsqu'elle est déjà connue ;
- le lien vers le dépôt **GitHub public** du projet.

Exemple de liste des membres :

IASD01 - Team Leader
IASD02 - Member
IASD03 - Member
IASD04 - Member

Rôle du dépôt GitHub :

La fourniture du lien GitHub dès la déclaration initiale est **strictement obligatoire**. Le dépôt constitue l'espace officiel permettant de suivre l'évolution technique du projet pendant toute la durée du semestre.

L'équipe pédagogique pourra notamment utiliser l'historique du dépôt pour observer :

- la progression générale du projet ;
- la fréquence et la régularité des commits ;
- l'évolution du code source ;
- la contribution individuelle des membres ;
- l'organisation du travail ;
- les modifications importantes apportées au projet ;

- la cohérence entre l'avancement déclaré par l'équipe et l'avancement réellement observable dans le dépôt.

Attention : le dépôt doit rester accessible pendant toute la durée du projet. La suppression, la privatisation ou le remplacement du dépôt sans notification préalable peut empêcher le suivi de l'équipe.

2. Étape 2 – Demandes de support et assistance technique

Cette communication peut être effectuée **à tout moment pendant le semestre** lorsqu'une équipe rencontre une difficulté ou nécessite une clarification concernant le projet.

Les demandes peuvent notamment concerner :

- le nettoyage et le prétraitement des données ;
- la gestion des valeurs manquantes ;
- la détection et le traitement des valeurs aberrantes ;
- l'encodage des variables catégorielles ;
- la normalisation ou la standardisation ;
- la sélection ou l'extraction des caractéristiques ;
- le choix d'un algorithme de Machine Learning ;
- l'entraînement et l'évaluation des modèles ;
- les métriques d'évaluation ;
- l'interprétation des résultats ;
- la visualisation des données ;
- l'implémentation de l'interface Streamlit ;
- les problèmes liés au code ou à l'environnement d'exécution.

Format obligatoire de l'objet :

[DM-2026] [QUESTION] Groupe <Code_Leader> - <Sujet_de_la_Question>

Exemple :

[DM-2026] [QUESTION] Groupe IASD01 - Standardisation et Encodage

Afin de permettre un traitement efficace de la demande, le message doit expliquer précisément :

- (a) le problème rencontré ;
- (b) ce qui a déjà été essayé ;
- (c) le résultat obtenu ;
- (d) le résultat attendu ;
- (e) les messages d'erreur éventuels ;
- (f) les parties pertinentes du code ;
- (g) les captures d'écran utiles, lorsque nécessaire.

Mauvais exemple :

“Notre code ne marche pas. Pouvez-vous nous aider ?”

Bon exemple :

“Après l’application de StandardScaler sur les variables numériques, notre modèle SVM produit une accuracy de 0.61 alors que sans standardisation nous obtenons 0.78. Nous avons vérifié les valeurs manquantes et les types des variables. Vous trouverez ci-joint le résultat ainsi que l’extrait du pipeline utilisé.”

Une question clairement formulée permet une réponse plus rapide et plus pertinente.

3. Étape 3 – Déclaration d’achèvement et déclenchement de l’évaluation

Lorsque l’équipe considère que son projet est **entièrement terminé**, le *Team Leader* doit envoyer un email officiel déclarant l’achèvement du projet.

Format obligatoire de l’objet :

[DM-2026] [RENDU-FINAL] Groupe <Code_Leader> - <Nom_du_Projet>

Exemple :

[DM-2026] [RENDU-FINAL] Groupe IASD01 - Prédiction Risque Cardiaque

Cet email constitue la **déclaration officielle de fin des travaux**. Il indique que l’équipe considère son projet suffisamment complet pour être soumis à l’évaluation finale.

Le message doit notamment confirmer :

- que tous les membres du groupe ont participé au projet ;
- que le dépôt GitHub contient la version finale du projet ;
- que le code source est accessible ;
- que les données et/ou liens vers les données nécessaires sont correctement documentés ;
- que le notebook ou les scripts d’analyse sont disponibles ;
- que les modèles finaux ont été entraînés et évalués ;
- que les résultats finaux sont documentés ;
- que l’application Streamlit, lorsqu’elle est requise, est fonctionnelle ;
- que la documentation du projet est complète.

2. Règles obligatoires concernant les objets des emails

Les objets des emails constituent une partie essentielle du système de suivi. Ils doivent être reproduits **exactement** selon les formats définis.

Type	Format obligatoire
Inscription	[DM-2026] [INSCRIPTION] Groupe <Code_Leader> - <Projet>
Question	[DM-2026] [QUESTION] Groupe <Code_Leader> - <Sujet>
Rendu final	[DM-2026] [RENDU-FINAL] Groupe <Code_Leader> - <Projet>

MODÈLE D'EMAIL D'INSCRIPTION À COPIER / COMPLÉTER

Objet : [DM-2026] [INSCRIPTION] Groupe IASD01 - Prédiction Risque Cardiaque

Corps du message :

Bonjour Monsieur,

Voici la déclaration d'inscription de notre équipe pour le mini-projet Data Mining:

1. COMPOSITION DE L'ÉQUIPE :

- Leader (IASD01) : Email: student1@mail.com github : <https://github.com/username1>
- Membre (IASD02) : Email: student2@mail.com github : <https://github.com/username2>
- Membre (IASD03) : Email: student3@mail.com github : <https://github.com/username3>

2. DÉTAILS DU PROJET :

- Titre du Projet : Prédiction du Risque Cardiaque par Data Mining
- Parcours choisi : Classification Supervisée
- Jeu de Données : Heart Disease Dataset (Kaggle) - 10 000+ lignes
- Lien Dépôt GitHub : https://github.com/.../DM_Project
- Lien Démo Streamlit (Optionnel) : <https://dmproject2.streamlit.app/>

Cordialement,
L'équipe IASD01

Les éléments suivants doivent être évités :

- supprimer les balises [DM-2026] ;
- modifier les mots INSCRIPTION, QUESTION ou RENDU-FINAL ;
- utiliser uniquement un objet générique tel que "Projet Data Mining" ;
- envoyer une demande importante sans identifier le groupe ;
- utiliser plusieurs formats différents pour un même type de demande.

3. Continuité et traçabilité des échanges

Pour chaque demande concernant un même problème, il est fortement recommandé de **répondre au même fil de discussion** plutôt que de créer plusieurs nouveaux emails.

Cette pratique permet de conserver :

- l'historique de la demande ;
- les réponses précédentes ;
- les fichiers et captures associés ;
- les décisions prises ;
- les clarifications fournies par l'équipe pédagogique.

Les équipes sont donc invitées à conserver une organisation cohérente de leurs échanges avec l'équipe pédagogique.

4. Conditions de prise en compte du rendu final

L'envoi de l'email [RENDU-FINAL] ne signifie pas automatiquement que le projet est conforme à toutes les exigences pédagogiques.

Il constitue la **notification officielle de disponibilité du projet pour évaluation**.

Avant l'envoi de cet email, le *Team Leader* doit donc vérifier que :

- le dépôt GitHub correspond bien à la version finale ;
- les fichiers nécessaires sont présents ;
- le code peut être exécuté ;
- les résultats présentés correspondent aux résultats réellement obtenus ;
- les expériences et évaluations sont documentées ;
- les membres du groupe sont correctement identifiés ;
- les éventuelles consignes spécifiques du projet ont été respectées.

Une fois le [RENDU-FINAL] envoyé, toute modification importante du projet doit être signalée à l'équipe pédagogique afin d'éviter toute ambiguïté sur la version effectivement soumise.

5. Déclenchement de l'évaluation

L'email portant l'objet :

[DM-2026] [RENDU-FINAL]

déclenche le processus d'évaluation du projet.

L'évaluation porte sur l'ensemble du travail réalisé par le groupe et conduit à l'attribution de la **note finale sur 20,0 points**, conformément à la grille d'évaluation du projet.

L'évaluation peut notamment prendre en compte :

- la compréhension et la formulation du problème ;
- la qualité et la pertinence des données utilisées ;
- la qualité du prétraitement ;
- la méthodologie de Data Mining adoptée ;
- la pertinence des modèles utilisés ;
- la qualité des expérimentations ;
- l'analyse et l'interprétation des résultats ;
- la qualité du code ;
- la qualité de l'application ou de l'interface ;
- la documentation ;
- l'organisation du dépôt GitHub ;
- la progression et la contribution des membres observables dans l'historique du projet.

Résumé de la procédure

PROCÉDURE À SUIVRE

1. **Avant le 15/09/2026** : envoyer [DM-2026] [INSCRIPTION] avec les informations du groupe, du sujet, du dataset et le lien GitHub.
2. **Pendant le projet** : utiliser [DM-2026] [QUESTION] pour toute demande officielle d'assistance ou de clarification.
3. **Pendant toute la durée du projet** : maintenir le dépôt GitHub accessible et régulièrement mis à jour afin de permettre le suivi de l'avancement.
4. **À la fin du projet** : vérifier l'ensemble des éléments du projet et publier la version finale sur GitHub.
5. **Déclaration finale** : envoyer [DM-2026] [RENDU-FINAL] pour déclarer officiellement que le projet est prêt pour l'évaluation.
6. **Évaluation** : l'envoi du [RENDU-FINAL] déclenche le processus d'évaluation et l'attribution de la note finale sur 20,0 points.

PÉRIODE ET CALENDRIER DE SOUMISSION DES PROJETS

Le dépôt des projets est officiellement ouvert dès le premier jour du cours et reste accessible jusqu'à une semaine après la fin de la semaine des derniers examens du semestre.

Bon travail à toutes les équipes !