

Directives & Cahier des Charges du Mini-Projet

Cours de Data Mining (Fouille de Données)

Année Académique : 2026/2027

EN BREF — RÈGLES ET MODALITÉS DU PROJET

- **Taille des Équipes** : De **3 étudiants minimum** à **6 étudiants maximum** par groupe.
- **Taille du Jeu de Données** : **Minimum 10 000 échantillons** ($\geq 10\,000$ lignes).
- **Domaine applicatif** : Libre choix (Santé, Finance, E-commerce, Vision, NLP, Énergie, etc.).
- **Parcours Technique** : Au choix entre **Classification Supervisée** OU **Clustering Non Supervisé** (ou Approche Hybride).
- **Livrable Applicatif** : Une application fonctionnelle et interactive (Web App Streamlit/Gradio/Flask, Desktop PyQt/Tkinter, ou Mobile App).
- **Modalités de Rendu** : **Pas de soutenance orale**. Évaluation uniquement sur le **Rapport PDF** (docs/Rapport_MiniProject.pdf) et le **Dépôt GitHub complet** (Code, Application, et README.md très détaillé).
- **Hébergement Git & Traçabilité** : Dépôt GitHub public obligatoire. **Historique des commits analysé individuellement**. Une absence de contributions Git personnelles entraînera une **pénalité lourde (note nulle)**.
- **Date Limite** : À la fin du semestre.

1. Objectifs et Philosophie du Mini-Projet

Le mini-projet constitue le pilier pratique du cours de **Data Mining**. Son objectif est de placer les étudiants dans la posture d'ingénieurs et de Data Scientists confrontés à un problème du monde réel.

Chaque équipe devra réaliser l'intégralité de la chaîne de traitement de données (*End-to-End Data Pipeline*), depuis la collecte et le prétraitement des données brutes jusqu'au déploiement d'une application décisionnelle interactive intégrant les algorithmes découverts en cours.

2. Organisation des Équipes et Suivi Git Strict

2.1. Composition des Groupes

- Les projets doivent être réalisés en équipes constituées de **3 étudiants au minimum** et **6 étudiants au maximum**.
- Aucun projet individuel ou en binôme ne sera accepté sans dérogation exceptionnelle accordée par l'enseignant.

2.2. Gestion de Version et Politique Git Obligatoire

ATTENTION — POLITIQUE DE TRAÇABILITÉ GIT STRICTE

1. Le projet doit être intégralement hébergé sur un dépôt **GitHub public**.
2. **Chaque membre du groupe doit posséder son propre compte GitHub** et contribuer activement par des commits réguliers, des branches explicites et des Pull Requests.
3. L'évaluation de l'implication individuelle sera effectuée via l'analyse des statistiques Git (*Git Commit History*, *Lines added/deleted*, *Pull Requests merged*).
4. **Pénalité Sanction** : Si un étudiant présente un historique Git vierge ou symbolique (ex: 1 unique commit la veille du rendu), **une note de zéro (0/20) lui sera attribuée à titre individuel**, quelle que soit la qualité globale du projet du groupe.

2.3. Règle d'Anonymisation sur les Supports Publics

CONFIDENTIALITÉ ET ANONYMAT SUR LES SUPPORTS PUBLIC

Dans l'ensemble des données et documents publics (**Dépôt GitHub**, README.md, Notebooks, Code source et **Rapport PDF**), **il est strictement interdit de mentionner les noms et prénoms réels des étudiants**.

- Seul le **code de l'étudiant** doit être utilisé.
- **Format du Code Étudiant** : Spécialité + Numéro d'ordre dans la liste du groupe (exemple : IASD01, IASD02, IASD03 pour le 3ème membre du groupe de la spécialité IASD).

2.4. Politique d'Utilisation des Outils d'IA et Responsabilité Académique

POLITIQUE D'USAGE DES OUTILS D'IA ET AUDIT D'AUTHENTICITÉ

1. **Usage Autorisé** : L'utilisation des assistants d'Intelligence Artificielle (ex : ChatGPT, Claude, Gemini, GitHub Copilot) est **autorisée** pour assister la rédaction, la recherche documentaire et le débogage de code.
2. **Responsabilité Pédagogique Totale** : Les étudiants demeurent **100% responsables** de l'exactitude scientifique, de la rigueur mathématique et de la validité de toutes les informations, formules et lignes de code fournies ou générées par des outils d'IA.
3. **Convocation à une Audition Orale d'Évaluation** : En cas de suspicion d'utilisation d'IA sans vérification préalable (ex : concepts hallucinés, réponses incohérentes ou code non maîtrisé), **les étudiants concernés pourront être convoqués individuellement à une audition orale d'évaluation**. L'étudiant devra répondre en détail à toutes les questions techniques sur son projet, son code et son rapport. Une incapacité à expliquer le travail entraînera des pénalités individuelles lourdes.

3. Exigences sur le Jeu de Données et le Domaine Applicatif

3.1. Choix du Domaine Applicatif

Le choix du domaine métier est totalement libre afin de permettre à chaque groupe de travailler sur une thématique passionnante. Exemples de domaines éligibles :

- **Finance & Banque** : Détection de fraudes par carte de crédit, scoring de crédit, prédiction du churn client.
- **Santé & Bioinformatique** : Diagnostic médical assisté, prédiction de maladies cardiaques/diabète, génomique.
- **E-commerce & Marketing** : Système de recommandation, segmentation d'acheteurs, analyse de sentiment des avis.
- **Transport & Smart Cities** : Prédiction de congestion routière, optimisation de flottes, consommation énergétique.
- **Traitement d'Images / NLP** : Classification de documents textuels, reconnaissance d'objets ou de signaux.

3.2. Volumétrie des Données

- Le dataset choisi doit comporter au **strict minimum 10 000 lignes** ($\geq 10\,000$ enregistrements).
- Le dataset doit contenir au minimum 8 à 10 attributs (numériques, catégoriels ou textuels) permettant de justifier des prétraitements et analyses complexes.
- Sources recommandées : Kaggle, UCI Machine Learning Repository, Google Dataset Search, data.gov, OpenData.

4. Parcours Techniques et Algorithmes du Cours

Chaque groupe doit choisir l'un des deux parcours principaux (ou proposer une approche hybride combinant les deux) :

PARCOURS A : CLASSIFICATION SUPERVISÉE

Si vous choisissez la classification supervisée, vous devez obligatoirement implémenter et comparer les algorithmes suivants :

1. **Classifieur de Référence (Baseline)** : Classifieur Naïf / Zero-R.
2. **K-Nearest Neighbors (K-NN)** : Étude de l'impact du paramètre K , des métriques de distance (Euclidienne, Manhattan) et de la standardisation des variables.
3. **Arbres de Décision & Random Forest** : Analyse du gain d'information (Entropie), Indice de Gini, élagage (*cost-complexity pruning*), et importance des variables.
4. **Classifieur Naïve Bayes** : Application de GaussianNB, MultinomialNB ou BernoulliNB avec gestion du lissage de Laplace.
5. **Support Vector Machines (SVM)** : Évaluation des noyaux (Linéaire, RBF, Polynomial) et réglage des hyperparamètres C et γ .

Évaluation : Matrice de confusion, Accuracy, Précision, Rappel, F1-Score, Courbe ROC-AUC et validation croisée (K -fold Cross Validation).

PARCOURS B : CLUSTERING NON SUPERVISÉ

Si vous choisissez le clustering non supervisé, vous devez obligatoirement implémenter et comparer les familles suivantes :

1. Méthodes de Partitionnement :

- ***K*-Means** : Recherche du *K* optimal via la méthode du coude (*Elbow Method*) et l'initialisation *K*-Means++.
- ***K*-Medoids (PAM)** : Comparaison de la robustesse aux valeurs aberrantes par rapport à *K*-Means.

2. Méthodes Hiérarchiques :

- **AGNES (Agglomératif)** : Construction et analyse des dendrogrammes avec critères de liaison (Ward, Complete, Single, Average).
- **DIANA (Divisif)** : Analyse top-down de la séparation des clusters.

Évaluation : Métriques internes (Score de Silhouette $s(i)$, Indice de Davies-Bouldin *DBI*, Indice de Dunn) et métriques externes si une vérité terrain existe (Rand Index *RI*, *ARI*, *NMI*). Visualisation 2D/3D via PCA.

5. Développement de l'Application Interactive

Le projet ne doit pas se limiter à des scripts Python ou des notebooks Jupyter. Chaque groupe doit développer une **application utilisateur fonctionnelle et déployée** :

- **Applications Web (Recommandé)** : Réalisées avec **Streamlit**, **Gradio**, **Dash** ou **Flask/React**.
- **Applications Desktop / Mobile** : Réalisées avec **PyQt**, **Tkinter**, **Kivy** ou **Flutter**.

Fonctionnalités minimales attendues dans l'application :

1. **Dashboard d'Exploration (EDA)** : Visualisation interactive des données, graphiques de distribution, matrice de corrélation.
2. **Module de Prédiction / Clustering en Temps Réel** : Formulaire permettant à un utilisateur d'aisément saisir de nouvelles valeurs et d'obtenir instantanément la classe prédite ou le cluster d'appartenance avec la probabilité/confiance associée.
3. **Comparateur de Modèles** : Affichage interactif des tableaux comparatifs de performances et des graphiques de métriques.

6. Structure Obligatoire du Dépôt GitHub & Contenu du README.md

6.1. Arborescence Standardisée du Projet

Chaque équipe doit respecter la structure de projet standardisée suivante dans son dépôt GitHub :

```
nom-du-projet-datamining/
|-- README.md           # Documentation principale (Instructions, Rôles, Objectifs, Rés
|-- data/
|   |-- raw/             # Données brutes (ou lien de téléchargement si > 100 Mo)
|   |-- processed/       # Données nettoyées et transformées
|-- notebooks/          # Notebooks Jupyter structurés étape par étape
|   |-- 01_eda_and_cleaning.ipynb
```

```
| |-- 02_preprocessing_encoding.ipynb
| '-- 03_model_training_evaluation.ipynb
|-- src/                                # Code source Python complet de l'application
| |-- app.py                            # Point d'entrée principal de l'application (ex: Streamlit)
| |-- preprocessing.py                  # Fonctions de nettoyage et préparation
| '-- models.py                        # Chargement des modèles et fonctions de prédiction
|-- docs/                              # Rapport scientifique complet au format PDF
| '-- Rapport_MiniProject.pdf
'-- requirements.txt                    # Liste exacte des dépendances Python (pandas, scikit-learn, et
```

6.2. Contenu Exigé du Fichier README.md sur GitHub

Le fichier README.md constitue le **rapport GitHub principal** de votre projet. Il doit obligatoirement inclure les 4 sections suivantes :

SECTION 1 : Présentation, Objectifs et Description du Projet

- Titre clair du projet et contexte métier.
- Description détaillée des objectifs scientifiques et applicatifs.
- Présentation du dataset (source, nombre d'échantillons $\geq 10\,000$, attributs clés).

SECTION 2 : Guide d'Installation et Lancement de l'Application

- Instructions étape par étape pour cloner le dépôt, installer les dépendances et exécuter l'application interactive localement. Exemple :

```
git clone https://github.com/votre-equipe/nom-du-projet.git
cd nom-du-projet
python -m venv venv && source venv/bin/activate # ou venv\Scripts\activate sous Windows
pip install -r requirements.txt
streamlit run src/app.py
```

- URL de déploiement en ligne le cas échéant (ex: Streamlit Community Cloud, Hugging Face Spaces).

SECTION 3 : Rôles des Membres et Matrice des Contributions

Tableau explicite détaillant les responsabilités exactes de chaque étudiant (**Règle d'anonymat** : utiliser uniquement le Code Étudiant, aucun Nom/Prénom réel) :

Étudiant (Code Étudiant)	Identifiant GitHub	Rôle & Contributions Principales
IASD01	@github_id1	EDA, Nettoyage des données, Implémentation K-NN & SVM.
IASD02	@github_id2	Arbres de Décision, Random Forest, Tuning d'hyperparamètres.
IASD03	@github_id3	Développement de l'Interface Web Streamlit & Déploiement.

SECTION 4 : Résultats Clés et Synthèse des Découvertes

- Tableau synthétique comparant les performances de tous les modèles testés (Accuracy, F1-Score, ROC-AUC ou Silhouette, DBI).
- Analyse critique du meilleur modèle retenu et principales conclusions métiers (*Key Findings*).

7. Grille d'Évaluation Hyper-Détaillée (Barème sur 20 Points)

L'évaluation repose sur un barème analytique sous-fractionné sur **20.0 Points**, évaluant chaque sous-élément technique du projet :

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
PARTIE 1 : RIGUEUR TECHNIQUE & DATA MINING (TOTAL : 10.0 POINTS)		
1.1 Prétraitement des Données	Nettoyage des valeurs manquantes/aberrantes, encodage des variables catégoriques (One-Hot/Label/Binary), normalisation/standardisation (Z-score/Min-Max/Robust Scaling).	2.0 pts
1.2 Analyse Exploratoire (EDA) & Tests Statistiques	Visualisations des distributions, matrices de corrélation, et réalisation obligatoire de tests statistiques (ex: χ^2 , ANOVA, test de Student, test de normalité Shapiro-Wilk, corrélations de Pearson/Spearman).	3.0 pts
1.3 Implémentation des Modèles du Cours	Implémentation et comparaison rigoureuse de TOUS les algorithmes requis du cours selon le parcours choisi (Zero-R, K-NN, Arbres/Random Forest, Naïve Bayes, SVM <i>OU</i> K-Means, K-Medoids, AGNES, DIANA).	1.0 pt
1.4 Optimization & Cross-Validation	Réglage méthodique des hyperparamètres (Grid-Search / RandomSearch) et évaluation par validation croisée (<i>K</i> -Fold Cross Validation, $K \geq 5$).	2.0 pts
1.5 Analyse des Métriques Comparatives	Tableau comparatif multicritère complet, matrices de confusion, courbes ROC-AUC, Precision/Recall/F1-Score (ou Silhouette $s(i)$, Davies-Bouldin <i>DBI</i> , Rand Index <i>RI</i>).	2.0 pts
PARTIE 2 : APPLICATION INTERACTIVE & ERGONOMIE (TOTAL : 4.0 POINTS)		
2.1 Architecture & Stabilité UI	Application fonctionnelle (Streamlit, Gradio, Web/Desktop), absence de bugs au runtime, code propre et modulaire dans <code>src/app.py</code> .	1.5 pts
2.2 Dashboard EDA Interactif	Composant d'exploration dynamique permettant à l'utilisateur de filtrer les données et visualiser interactivement les graphiques.	1.0 pt
2.3 Prédiction / Clustering Temps Réel	Formulaire interactif de saisie dynamique des valeurs d'entrée générant des prédictions/clustérings instantanés avec probabilité/confiance.	1.5 pts
PARTIE 3 : TRAÇABILITÉ GIT & COMMITS INDIVIDUELS (TOTAL : 3.0 POINTS)		
3.1 Discipline & Structure du Dépôt	Respect strict de l'arborescence recommandée (<code>data/</code> , <code>notebooks/</code> , <code>src/</code> , <code>docs/</code>), présence du fichier <code>requirements.txt</code> et clarté des messages de commit.	1.0 pt
3.2 Commits & Contributions Individuelles	Régularité des commits personnels par étudiant sur GitHub, équité de la participation. Note : Pénalité de 0/20 attribuée individuellement si l'historique d'un membre est vierge.	2.0 pts
PARTIE 4 : RAPPORT PDF & DOCUMENTATION GITHUB (TOTAL : 3.0 POINTS)		

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
4.1 Rapport Scientifique PDF	Rapport académique rédigé dans docs/Rapport_MiniProject.pdf (Problématique, méthodologie, justifications théoriques des algorithmes, interprétation des résultats).	1.5 pts
4.2 Documentation README.md GitHub	Fichier README.md exemplaire incluant la présentation, le guide d'installation/lancement pas-à-pas, la matrice des rôles/contributions nominative et la synthèse des résultats clés.	1.5 pts
TOTAL GÉNÉRAL	Évaluation Finale du Mini-Projet (Sans Soutenance Orale)	20.0 pts

8. Exemple d'Application Référence & Ressources d'Illustration

Pour illustrer concrètement l'ensemble des exigences du cahier des charges, un **projet modèle de référence complet** a été développé et rendu public. Ce projet démontre la qualité attendue sur la chaîne Data Mining, l'application web et la documentation.

PROJET MODÈLE : PRÉDICTION DU RISQUE CARDIAQUE PAR DATA MINING

- **Thématique Métier** : Santé & Cardiologie Prédictive (Diagnostic assisté non invasif).
- **Jeu de Données** : Kaggle uditjain13/heart-disease-risk-2026 ($N = 9\,000$ enregistrements, 25 attributs).
- **Traitements** : Encodage et standardisation sans fuite de données (ColumnTransformer), 6 tests statistiques (χ^2 , Mann-Whitney U , Spearman) avec corrections Benjamini-Hochberg FDR.
- **Modélisation** : Benchmark de 6 classifieurs (Zero-R, K-NN, Arbre, Random Forest, Naïve Bayes, SVM). Le SVM (RBF) obtient une Accuracy de **89,17%** et un ROC-AUC de **0.9422**.
- **Application Déployée** : Dashboard Streamlit 9 pages avec une échelle de stratification clinique à 7 niveaux (0% à 100%) et des curseurs interactifs.

8.1. Liens Directs vers les Ressources en Ligne

- **Dépôt GitHub Public** : <https://github.com/hosniadilemp-a11y/DataMiningProjectExample.git>
- **Application Web Déployée (Live Streamlit Cloud)** : <https://dmproject2.streamlit.app/>
- **Exemple de Rapport Scientifique PDF (40 pages)** : https://github.com/hosniadilemp-a11y/DataMiningProjectExample/blob/main/docs/Rapport_MiniProject.pdf

8.2. Captures d'Écran et Visualisations de Performance Référence




Figure 1: Comparaison des Courbes ROC (Discrimination maximale SVM AUC = 0.9422).




Figure 2: Grille des Matrices de Confusion des 6 Algorithmes Benchmarkés.




Figure 3: Analyse Multi-Perspective des Variables Clés (Fréquence Cardiaque Max, Dépression ST, Âge, LDL).

9. Modalités de Communication, Suivi et Directives Obligatoires par Email

DIRECTIVES OFFICIELLES DE COMMUNICATION, DE SUIVI ET DE RENDU

Principe général.

Afin de garantir une communication centralisée, une traçabilité complète des échanges et un suivi équitable de l'avancement des différents groupes, l'ensemble des communications officielles relatives au projet de Data Mining doit obligatoirement être effectué par l'intermédiaire de l'adresse email officielle du projet :

`datamining.project.student@gmail.com`

Important : les communications officielles doivent être envoyées **exclusivement par le chef de groupe (*Team Leader*)**. Les membres d'un groupe peuvent participer à la préparation du contenu du message, mais le *Team Leader* demeure le responsable de l'envoi et du suivi des échanges avec l'équipe pédagogique.

Pour faciliter l'identification automatique des messages et assurer leur classement, chaque email doit respecter strictement le format d'objet correspondant à sa nature. Tout email ne respectant pas les conventions définies ci-dessous pourra être retardé dans son traitement ou nécessiter une nouvelle soumission correctement formatée.

1. Cycle officiel de communication

Les échanges relatifs au projet sont organisés autour de trois étapes principales :

1. Étape 1 – Déclaration obligatoire de l'équipe et du sujet

Date limite : 15 septembre 2026

Avant le **15 septembre 2026**, chaque *Team Leader* doit envoyer un email officiel permettant d'enregistrer définitivement son groupe et son sujet de projet.

Destinataire obligatoire :

`datamining.project.student@gmail.com`

Format obligatoire de l'objet :

`[DM-2026] [INSCRIPTION] Groupe <Code_Leader> - <Nom_du_Projet>`

Exemple :

`[DM-2026] [INSCRIPTION] Groupe IASD01 - Prédiction Risque Cardiaque`

Le corps de l'email doit obligatoirement contenir :

- le code étudiant du *Team Leader* ;
- les codes étudiants de tous les membres du groupe ;
- le nom ou titre provisoire du projet ;
- le domaine métier ou domaine d'application ;
- une description claire du problème à résoudre ;
- une description du ou des datasets envisagés ;
- la source du dataset et, lorsque cela est possible, son URL ;
- le nombre approximatif d'observations et de variables ;
- la variable cible (*target*) envisagée, lorsqu'elle est déjà connue ;
- le lien vers le dépôt **GitHub public** du projet.

Exemple de liste des membres :

IASD01 - Team Leader
IASD02 - Member
IASD03 - Member
IASD04 - Member

Rôle du dépôt GitHub :

La fourniture du lien GitHub dès la déclaration initiale est **strictement obligatoire**. Le dépôt constitue l'espace officiel permettant de suivre l'évolution technique du projet pendant toute la durée du semestre.

L'équipe pédagogique pourra notamment utiliser l'historique du dépôt pour observer :

- la progression générale du projet ;
- la fréquence et la régularité des commits ;
- l'évolution du code source ;
- la contribution individuelle des membres ;
- l'organisation du travail ;
- les modifications importantes apportées au projet ;

- la cohérence entre l'avancement déclaré par l'équipe et l'avancement réellement observable dans le dépôt.

Attention : le dépôt doit rester accessible pendant toute la durée du projet. La suppression, la privatisation ou le remplacement du dépôt sans notification préalable peut empêcher le suivi de l'équipe.

2. Étape 2 – Demandes de support et assistance technique

Cette communication peut être effectuée **à tout moment pendant le semestre** lorsqu'une équipe rencontre une difficulté ou nécessite une clarification concernant le projet.

Les demandes peuvent notamment concerner :

- le nettoyage et le prétraitement des données ;
- la gestion des valeurs manquantes ;
- la détection et le traitement des valeurs aberrantes ;
- l'encodage des variables catégorielles ;
- la normalisation ou la standardisation ;
- la sélection ou l'extraction des caractéristiques ;
- le choix d'un algorithme de Machine Learning ;
- l'entraînement et l'évaluation des modèles ;
- les métriques d'évaluation ;
- l'interprétation des résultats ;
- la visualisation des données ;
- l'implémentation de l'interface Streamlit ;
- les problèmes liés au code ou à l'environnement d'exécution.

Format obligatoire de l'objet :

[DM-2026] [QUESTION] Groupe <Code_Leader> - <Sujet_de_la_Question>

Exemple :

[DM-2026] [QUESTION] Groupe IASD01 - Standardisation et Encodage

Afin de permettre un traitement efficace de la demande, le message doit expliquer précisément :

- (a) le problème rencontré ;
- (b) ce qui a déjà été essayé ;
- (c) le résultat obtenu ;
- (d) le résultat attendu ;
- (e) les messages d'erreur éventuels ;
- (f) les parties pertinentes du code ;
- (g) les captures d'écran utiles, lorsque nécessaire.

Mauvais exemple :

"Notre code ne marche pas. Pouvez-vous nous aider ?"

Bon exemple :

“Après l’application de StandardScaler sur les variables numériques, notre modèle SVM produit une accuracy de 0.61 alors que sans standardisation nous obtenons 0.78. Nous avons vérifié les valeurs manquantes et les types des variables. Vous trouverez ci-joint le résultat ainsi que l’extrait du pipeline utilisé.”

Une question clairement formulée permet une réponse plus rapide et plus pertinente.

3. Étape 3 – Déclaration d’achèvement et déclenchement de l’évaluation

Lorsque l’équipe considère que son projet est **entièrement terminé**, le *Team Leader* doit envoyer un email officiel déclarant l’achèvement du projet.

Format obligatoire de l’objet :

[DM-2026] [RENDU-FINAL] Groupe <Code_Leader> - <Nom_du_Projet>

Exemple :

[DM-2026] [RENDU-FINAL] Groupe IASD01 - Prédiction Risque Cardiaque

Cet email constitue la **déclaration officielle de fin des travaux**. Il indique que l’équipe considère son projet suffisamment complet pour être soumis à l’évaluation finale.

Le message doit notamment confirmer :

- que tous les membres du groupe ont participé au projet ;
- que le dépôt GitHub contient la version finale du projet ;
- que le code source est accessible ;
- que les données et/ou liens vers les données nécessaires sont correctement documentés ;
- que le notebook ou les scripts d’analyse sont disponibles ;
- que les modèles finaux ont été entraînés et évalués ;
- que les résultats finaux sont documentés ;
- que l’application Streamlit, lorsqu’elle est requise, est fonctionnelle ;
- que la documentation du projet est complète.

2. Règles obligatoires concernant les objets des emails

Les objets des emails constituent une partie essentielle du système de suivi. Ils doivent être reproduits **exactement** selon les formats définis.

Type	Format obligatoire
Inscription	[DM-2026] [INSCRIPTION] Groupe <Code_Leader> - <Projet>
Question	[DM-2026] [QUESTION] Groupe <Code_Leader> - <Sujet>
Rendu final	[DM-2026] [RENDU-FINAL] Groupe <Code_Leader> - <Projet>

Les éléments suivants doivent être évités :

- supprimer les balises [DM-2026] ;

- modifier les mots INSCRIPTION, QUESTION ou RENDU-FINAL ;
- utiliser uniquement un objet générique tel que “Projet Data Mining” ;
- envoyer une demande importante sans identifier le groupe ;
- utiliser plusieurs formats différents pour un même type de demande.

3. Continuité et traçabilité des échanges

Pour chaque demande concernant un même problème, il est fortement recommandé de **répondre au même fil de discussion** plutôt que de créer plusieurs nouveaux emails.

Cette pratique permet de conserver :

- l'historique de la demande ;
- les réponses précédentes ;
- les fichiers et captures associés ;
- les décisions prises ;
- les clarifications fournies par l'équipe pédagogique.

Les équipes sont donc invitées à conserver une organisation cohérente de leurs échanges avec l'équipe pédagogique.

4. Conditions de prise en compte du rendu final

L'envoi de l'email [RENDU-FINAL] ne signifie pas automatiquement que le projet est conforme à toutes les exigences pédagogiques.

Il constitue la **notification officielle de disponibilité du projet pour évaluation**.

Avant l'envoi de cet email, le *Team Leader* doit donc vérifier que :

- le dépôt GitHub correspond bien à la version finale ;
- les fichiers nécessaires sont présents ;
- le code peut être exécuté ;
- les résultats présentés correspondent aux résultats réellement obtenus ;
- les expériences et évaluations sont documentées ;
- les membres du groupe sont correctement identifiés ;
- les éventuelles consignes spécifiques du projet ont été respectées.

Une fois le [RENDU-FINAL] envoyé, toute modification importante du projet doit être signalée à l'équipe pédagogique afin d'éviter toute ambiguïté sur la version effectivement soumise.

5. Déclenchement de l'évaluation

L'email portant l'objet :

[DM-2026] [RENDU-FINAL]

déclenche le processus d'évaluation du projet.

L'évaluation porte sur l'ensemble du travail réalisé par le groupe et conduit à l'attribution de la **note finale sur 20,0 points**, conformément à la grille d'évaluation du projet.

L'évaluation peut notamment prendre en compte :

- la compréhension et la formulation du problème ;
- la qualité et la pertinence des données utilisées ;
- la qualité du prétraitement ;
- la méthodologie de Data Mining adoptée ;
- la pertinence des modèles utilisés ;
- la qualité des expérimentations ;
- l'analyse et l'interprétation des résultats ;
- la qualité du code ;
- la qualité de l'application ou de l'interface ;
- la documentation ;
- l'organisation du dépôt GitHub ;
- la progression et la contribution des membres observables dans l'historique du projet.

Résumé de la procédure

PROCÉDURE À SUIVRE

1. **Avant le 15/09/2026** : envoyer [DM-2026] [INSCRIPTION] avec les informations du groupe, du sujet, du dataset et le lien GitHub.
2. **Pendant le projet** : utiliser [DM-2026] [QUESTION] pour toute demande officielle d'assistance ou de clarification.
3. **Pendant toute la durée du projet** : maintenir le dépôt GitHub accessible et régulièrement mis à jour afin de permettre le suivi de l'avancement.
4. **À la fin du projet** : vérifier l'ensemble des éléments du projet et publier la version finale sur GitHub.
5. **Déclaration finale** : envoyer [DM-2026] [RENDU-FINAL] pour déclarer officiellement que le projet est prêt pour l'évaluation.
6. **Évaluation** : l'envoi du [RENDU-FINAL] déclenche le processus d'évaluation et l'attribution de la note finale sur 20,0 points.

PÉRIODE ET CALENDRIER DE SOUMISSION DES PROJETS

Le dépôt des projets est officiellement ouvert dès le premier jour du cours et reste accessible jusqu'à une semaine après la fin de la semaine des derniers examens du semestre.

Bon travail à toutes les équipes !